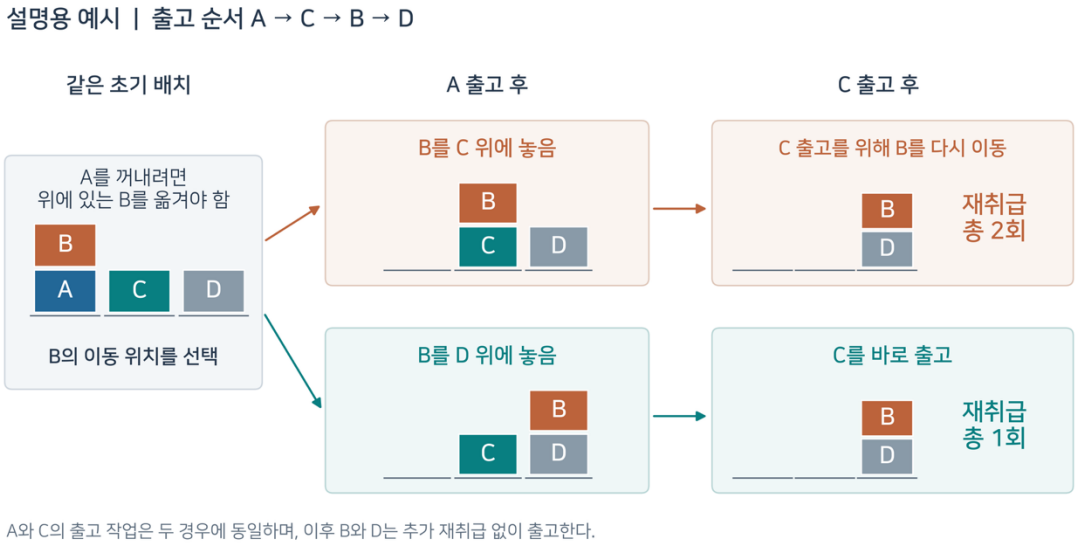
컨테이너 재취급 감소를 위한 AI 기반 이동 위치 선정 방안

1. 연구 배경과 문제 정의

1.1. 컨테이너 재취급의 발생 구조

항만 야드는 선박과 육상 운송 사이에서 컨테이너를 일시적으로 보관하는 공간이다. 컨테이너를 여러 단으로 쌓으면 공간을 효율적으로 사용할 수 있지만, 아래쪽 컨테이너를 꺼내려면 위에 놓인 컨테이너를 먼저 옮겨야 한다. 이처럼 출고 대상을 꺼내기 위해 다른 컨테이너를 이동하는 작업을 재취급이라고 한다.[1]

그림 1-1. 이동 위치에 따른 컨테이너 재취급의 차이



주: 출고 순서가 A→C→B→D인 설명용 예시, 재취급 횟수에서 필수 출고 작업 제외

그림 1-1에서 A를 꺼내려면 위에 놓인 B를 다른 열로 옮겨야 한다. B를 다음 출고 대상인 C 위에 놓으면 C를 꺼낼 때 B를 다시 옮겨 재취급이 2회 발생하고, D 위에 놓으면 1회로 끝난다. 같은 배치와 출고 순서에서도 현재의 이동 위치가 이후 작업량을 결정하므로, 이후 출고까지 고려해 위치를 선택하면 같은 물량을 처리하는 데 필요한 재취급을 줄일 수 있다.

1.2. 출고 순서의 불확실성과 이동 위치 결정의 어려움

이동 위치를 정하려면 적재 가능한 공간과 함께 각 컨테이너의 출고 시점을 고려해야 한다. 실제 항만에서는 차량 도착과 선박 작업의 진행에 따라 출고 요청 순서가 달라지므로, 앞으로 꺼낼 순서를 미리 확정하기 어렵다.[1] 적재 높이가 낮은 열이나 예상 출고 시점이 늦은 컨테이너 위를 선택하는 규칙은 단순하지만, 하나의 기준으로는 옮긴 컨테이너가 다른 컨테이너의 출고를 막을 가능성과 이후에 사용할 빈 공간을 함께 평가하기 어렵다.

항만 분야에서도 적재 의사결정에 AI를 활용하려는 움직임이 나타나고 있다. 부산항만공사는 2026년 발표한 부산항 AX 추진계획에 AI를 활용한 컨테이너 적재 위치 결정과 디지털트윈을 통

한 운영 시나리오 검증을 포함했다.[2] 본 제안에서는 이러한 방향을 재취급 과정의 이동 위치 추천이라는 구체적인 의사결정 문제로 다룬다.

1.3. 연구 목적과 분석 범위

본 제안의 목적은 현재 적재 상태와 컨테이너별 출고 확률을 바탕으로 이후 재취급이 적게 발생할 이동 위치를 추천하는 것이다. 공개 연구 자료에서 규칙 기반 방법, 학습한 AI, 미래 탐색의 재취급 횟수와 계산시간을 비교하고, 야드 운영 담당자의 활용 방식과 시범 운영안을 제시한다.

2. 제안 아이디어와 활용 방식

2.1. AI 기반 이동 위치 추천의 개념

Yardwise는 출고 대상 위에 놓인 컨테이너를 어느 열로 옮길지 제안하는 서비스이다. 현재 적재 상태와 컨테이너별 출고 확률에서 계산한 변수를 AI 모형에 입력해 후보 위치별 이후 재취급의 상대 비용을 예측하고, 비용이 가장 작은 위치를 추천한다. 이번 실험에서는 공개 연구 자료의 출고 확률을 활용하였다. 한 번의 이동이 끝나면 변경된 배치에서 다음 위치를 다시 추천한다.

2.2. 적용 대상과 업무 활용 시나리오

주요 사용자는 컨테이너 터미널의 야드 운영 담당자이다. 담당자는 목표 컨테이너 위에 다른 컨테이너가 놓여 있을 때 추천 위치와 함께 후보 열의 적재 높이, 남은 공간, 목적열 컨테이너와 출고 순서가 충돌할 위험을 화면에서 확인한다. 이어 AI 추천 위치와 다른 후보를 비교하고, 장비 접근 여건과 현장 상황에 따라 이동 위치를 확정한다.

2.3. 선행연구와 본 제안의 접근

Zhang 외는 실제 운영 자료로 출고 확률을 추정하고, 가능한 미래 상황을 탐색해 기대 재취급 횟수를 줄이는 방법을 제시했다.[1] 본 제안에서는 학습 단계에서 여러 가상 출고 순서를 시험하여, 컨테이너를 어느 위치로 옮겼을 때 이후 재취급이 적게 발생하는지 평가하고, 그 결과를 AI 모형에 학습시켜 추천 단계에서는 현재 배치와 출고 확률만으로 후보 위치를 평가한다. 현장에서는 AI로 이동 위치를 우선 추천하고, 재취급이 많이 발생한 사례는 가상 출고 실험으로 다시 검토한다.

2.4. 활용 시나리오와 화면 구성

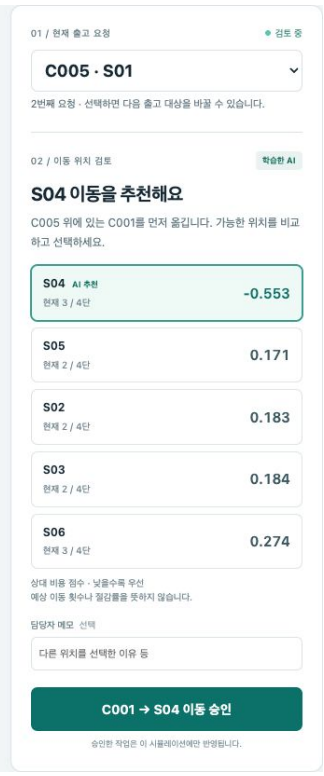
그림 2-1은 적재열 6개, 최대 높이 4단, 컨테이너 16개로 구성된 평가 사례를 프로토타입에서 처리한 화면이다. 담당자가 이동 위치를 확정하면 변경된 배치와 작업 이력이 화면에 반영되며, 웹사이트의 계산 코드가 실험과 같은 재취급 횟수를 산출하는지 확인하였다.

그림 2-1. Yardwise의 이동 위치 추천과 처리 결과 및 작업 이력

(a) 현재 배치와 후보별 추천 결과



(b) 끝까지 처리한 결과 비교



(c) 담당자가 승인한 작업 이력





자료: 본 제안의 공개 프로토타입 화면, (a)는 이동 승인 전·(c)는 해당 이동 승인 후의 기록

(a)에서 출고 대상 C005 위의 C001을 옮길 후보를 비교하고 S04 이동을 승인한다. 점수는 후보 간 상대 비용으로, 예상 재취급 횟수 자체는 아니다. (b)는 같은 초기 배치를 각 방법으로 끝까지 처리한 비교 결과이며, (c)에서는 승인한 출고와 이동을 확인하고 기록을 저장한다.

접속 주소: zzongzzz47.github.io/yardwise

3. 데이터와 실험 설계

3.1. 활용 데이터와 적재 조건

분석에는 공개 연구 자료인 「Probabilistic Container Relocation Problem」 Version 3을 활용하였다. 이 자료는 실제 운영 자료에서 도출한 출고 확률 행렬과 계산 실험용 컨테이너 배치로 구성되며, 각 실험 자료에는 초기 적재 상태, 최대 적재 높이, 출고 요청 순서와 컨테이너별 출고 확률이 포함되어 있다.[3]

적재열 수와 높이, 적재 밀도가 다른 56개 조건에서 조건별 12개씩 총 672개 배치를 선정하였다. 적재열은 4~10개, 최대 높이는 3~6단, 배치당 컨테이너는 6~40개이다. 출고 확률은 컨테이너가 12개 시간 구간의 각 구간에 출고될 가능성을 나타내며, 컨테이너별 출고 확률의 합이 1이 되도록 정규화하였다. 평가 대상은 같은 규격의 컨테이너가 놓인 한 구역에서 모든 컨테이너를 출고하는 과정이다.

3.2. 분석 변수와 판단에 사용하는 정보

AI의 입력 변수는 현재 배치와 출고 확률에서 계산한 40개 항목이다. 변수는 후보 위치의 적재 상태와 남은 공간, 옮긴 컨테이너가 이후 출고를 방해할 가능성을 나타내며, 주요 구성은 표 3-1과 같다.

표 3-1. 주요 분석 변수와 역할

구분	대표 변수	판단에 사용하는 내용
적재 구조	출발열·목적열 높이, 최대 적재 높이, 적재열 수	현재 배치와 후보 위치의 상태
공간 여유	빈 열 수, 남은 적재 칸 수, 가득 찬 열 수	이후 이동에 사용할 공간
출고 시점과 불확실성	예상 출고 구간, 표준편차, 구간별 확률	출고가 빠르거나 늦을 가능성
목적열의 충돌 위험	목적열 컨테이너와의 예상 출고 시점 차이, 차단 위험 지표	옮긴 컨테이너가 아래 컨테이너의 출고를 막을 가능성
전체 배치의 상태	남은 컨테이너 수, 예상 출고 시점의 상대 순위, 배치 전체의 차단 위험 지표	후보를 전체 작업 상황과 함께 평가

3.3. 학습 자료와 평가 자료의 구분

672개 배치를 학습용 336개, 검증용 112개, 평가용 224개로 구분하였다. 각 배치 조건에서 원본 번호 0~5의 6개는 학습, 6~7의 2개는 검증, 8~11의 4개는 평가에 사용하였으며, 세 집단 사이에 동일한 초기 배치는 없다. 하이퍼파라미터는 4.3절의 값으로 고정하고 검증용 배치에서 학습 결과를 점검하였다. 평가용 배치는 학습에 사용하지 않았지만 개발 과정에서 반복 활용한 벤치마크이므로, 현장 검증에서는 별도 기간의 자료로 평가한다.

4. AI 학습과 이동 위치 선정 방법

4.1. 재취급 감소 목표와 이동 가능 조건

본 제안의 목표는 주어진 컨테이너를 모두 출고하는 과정에서 발생하는 재취급 횟수를 줄이는 것이다. 출고할 컨테이너 위에 다른 컨테이너가 있으면 최상단 컨테이너부터 이동 위치를 결정하며, 이동 위치는 다음 조건을 만족해야 한다.

1) 각 열의 최상단 컨테이너만 이동할 수 있다.

2) 현재 컨테이너가 놓인 열을 제외한 다른 열로 이동한다.

3) 이동 후에도 목적열의 최대 적재 높이를 넘지 않는다.

4) 현재 출고 요청을 막는 컨테이너를 이동하며, 요청된 순서대로 출고한다.

이 조건을 만족하는 위치의 집합을 후보 집합 $A(s)$로 정의하며, AI와 비교 방법은 모두 같은 후보 집합에서 위치를 선택한다.

4.2. 가상 출고 순서를 활용한 학습 자료 생성

학습용 336개 배치를 높이 우선 규칙, 출고 우선순위 규칙, 확률 위험 규칙, 무작위 이동의 네 방식으로 각각 끝까지 진행해 1,344개 경로에서 이동 판단 14,848번을 수집하였다. 이 네 방식은 판단 상황을 만드는 데에만 사용하였다. 판단마다 출고 확률을 바탕으로 가상 출고 순서 12개를 생성하고, 같은 판단의 모든 후보를 이 12개 순서로 동일하게 평가하였다. 가상 순서에서는 현재 요청된 컨테이너를 먼저 출고하고, 나머지는 각자의 확률 분포에서 출고 구간을 추출한 뒤 같은 구간 안의 순서를 무작위로 정하였다. 후보 위치로 옮긴 뒤 남은 작업에는 출고 순위를 고려하는 규칙을 적용해 재취급 횟수를 계산하였으며, 후보 위치의 평균 비용은 식 (1)과 같다. 이 가상 순서는 학습 정답을 만드는 데에만 사용하고, 성능 평가는 평가용 배치의 출고 요청 순서로 수행하였다.

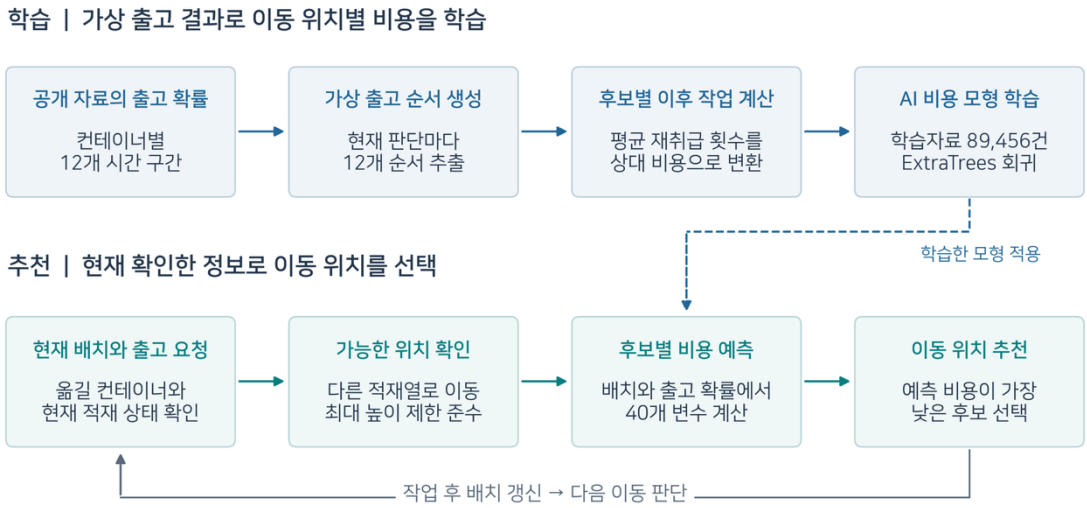
$$\overline{C}(s,a) = \frac{1}{K}\sum_{k=1}^{K} R(s,a;\omega_k)\,,\ K = 12 \tag{1}$$

여기서 s는 현재 배치와 출고 요청 등의 상태, a는 이동할 위치, ω_k는 k번째 가상 출고 순서이며, $R(s,a;\omega_k)$는 해당 위치로 옮기는 작업부터 남은 출고를 마칠 때까지의 재취급 횟수이다. 학습 정답은 식 (2)와 같이 후보의 평균 비용에서 같은 의사결정에 속한 후보 비용의 평균을 뺀 상대 비용으로 설정하였다.

$$q(s,a) = \overline{C}(s,a) - \frac{1}{|A(s)|}\sum_{b\in A(s)} \overline{C}(s,b) \tag{2}$$

상대 비용이 작을수록 같은 상황의 다른 후보보다 추가 작업이 적으며, 후보별 상대 비용 89,456건을 학습자료로 사용하였다.

그림 4-1. 가상 출고 순서를 활용한 AI 학습과 이동 위치 추천 과정



주: 출고 확률은 공개 연구 자료의 제공값, 학습 대상은 후보 위치별 이후 재취급의 상대 비용

4.3. AI의 후보 평가와 위치 선택

그림 4-1과 같이 학습 단계에서는 가상 출고 순서로 계산한 상대 비용을 정답으로 사용하고, 추천 단계에서는 가상 순서를 새로 만들지 않고 학습한 모형으로 후보별 비용을 예측한다. 예측

모형으로는 여러 회귀나무의 예측을 결합하는 ExtraTrees 회귀모형을 사용하였다.[4] 나무 수는 100개, 최대 깊이는 16, 말단 노드의 최소 표본 수는 8로 설정하고, 40개 변수를 입력하였다.

추천 단계에서는 식 (3)과 같이 예측 상대 비용이 가장 작은 위치를 선택한다.

$$a^* = \arg\min_{a \in A(s)} \hat{q}_\theta(s, a) \tag{3}$$

$\hat{q}_\theta(s, a)$는 학습한 모형이 예측한 후보 위치의 상대 비용이다. 예측값이 -0.4와 0.2인 두 후보가 있으면 -0.4의 후보를 선택하며, 이 값은 후보 간 비교 점수이므로 음수가 실제 이동 횟수를 뜻하지는 않는다. 이동 후에는 적재 상태를 갱신하고 다음 결정에서 같은 방식으로 후보를 비교한다.

4.4. 비교 방법과 평가 지표

표 4-1의 다섯 가지 방법을 동일한 초기 배치, 출고 요청 순서와 최대 적재 높이 조건에서 비교하였다. 높이 우선 규칙을 제외한 네 방법에는 같은 출고 확률을 제공하였으며, 매 결정 시점에는 현재 출고 요청만 공개하고 이후 요청은 작업 진행에 따라 순차적으로 제시하였다. 출고 우선순위 규칙을 주된 비교 기준으로 삼고, 같은 확률을 사용하는 확률 위험 규칙과 미래 탐색의 결과도 함께 검토하였다.

표 4-1. 비교 방법과 이동 위치 선정 기준

방법	선정 기준	출고 확률 활용 방식
높이 우선 규칙	적재 높이가 가장 낮은 후보를 우선 선택	사용하지 않음(적재 높이로 판단)
출고 우선순위 규칙	아래 컨테이너의 출고를 가리지 않는 후보 우선 선택	같은 확률의 평균 출고 시점
확률 위험 규칙	차단 위험 지표가 가장 작은 후보 선택	같은 확률에서 계산한 출고 선후 관계의 위험 지표
학습한 AI	예측한 상대 비용이 가장 작은 후보 선택	출고 확률과 적재 상태에서 계산한 변수 40개
미래 탐색	후보별 평균 재취급을 직접 계산해 최소 후보 선택	같은 확률에서 가상 출고 순서 24개를 생성해 후보 평가

주요 지표는 재취급 횟수와, 여기에 필수 출고 작업을 더한 전체 이동 횟수이다. 감소율은 평가 배치 전체의 합계를 기준 방법과 비교해 산출하였다. 배치별로 AI의 재취급이 감소, 동일, 증가한 경우를 구분하고, 의사결정 계산시간은 후보 평가와 위치 선택에 걸린 시간을 이동 결정 횟수로 나눈 평균으로 측정하였다.

5. 실험 결과와 해석

5.1. 방법별 재취급과 전체 이동 비교

평가용 224개 배치에서 컨테이너 4,132개를 모두 출고하며 발생한 재취급 횟수를 비교하였다. AI를 적용한 경우 재취급은 1,919회로, 출고 우선순위 규칙의 2,118회보다 199회(9.4%) 감소하였다. 확률 위험 규칙의 2,095회보다도 176회(8.4%) 적어, 같은 출고 확률을 사용한 두 규칙보다

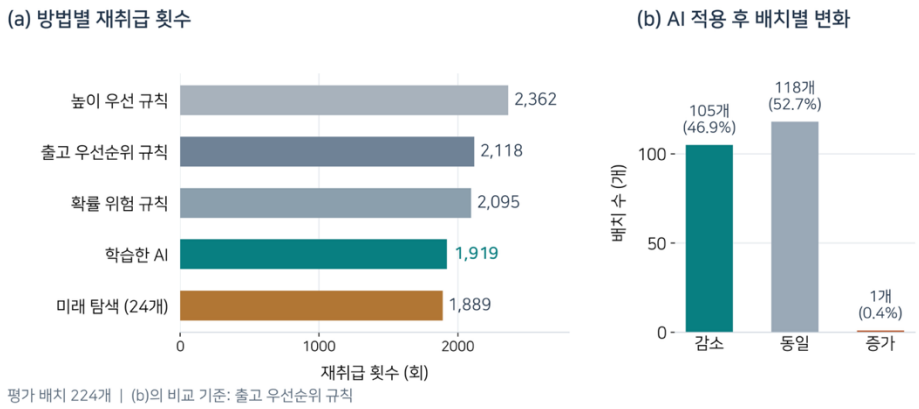
재취급이 줄었다.

표 5-1. 방법별 재취급 및 전체 이동 횟수

방법	재취급 합계(회)	배치당 평균 재취급(회)	전체 이동(회)
높이 우선 규칙	2,362	10.54	6,494
출고 우선순위 규칙	2,118	9.46	6,250
확률 위험 규칙	2,095	9.35	6,227
학습한 AI	1,919	8.57	6,051
미래 탐색	1,889	8.43	6,021

주: 전체 이동은 재취급과 필수 출고 4,132회의 합

그림 5-1. 방법별 재취급 횟수와 AI 적용 후 배치별 변화



주: 동일한 224개 평가 배치의 비교 결과, (b)는 출고 우선순위 규칙 기준 재취급 횟수의 감소·동일·증가 구분

5.2. 개선 사례와 악화 사례의 분석

그림 5-1(b)와 같이 출고 우선순위 규칙과 비교해 AI의 재취급은 절반에 가까운 배치에서 감소하였고, 절반 이상의 배치에서는 같았으며, 1개 배치에서 증가하였다. 전체 감소는 여러 배치의 개선이 누적된 결과이다.

개선 사례인 6개 적재열, 최대 4단, 컨테이너 16개의 배치에서는 출고 우선순위 규칙이 8회, AI가 7회의 재취급을 기록하였다. 두 방법은 같은 초기 상태에서 출발했지만 방해 컨테이너를 놓는 목적열을 다르게 선택하면서 이후 배치가 달라졌다. 재취급이 증가한 배치는 컨테이너 23개로 구성되었으며, 규칙이 13회, AI가 14회였다. 모형이 유리하다고 예측한 위치가 실제 출고 순서에서 추가 이동으로 이어진 사례로, 현장에서는 이러한 사례를 기록해 출고 확률과 추천 판단을 함께 점검한다(7.2절).

5.3. AI와 미래 탐색의 성능 비교

가상 출고 순서 24개를 직접 계산한 미래 탐색의 재취급은 1,889회로, AI의 1,919회보다 30회 적었다. 두 방법의 차이는 미래 탐색 대비 약 1.6%이며, 출고 우선순위 규칙 대비 감소율은 각각 10.8%와 9.4%였다. 의사결정당 평균 계산시간은 AI 1.59ms, 미래 탐색 3.81ms였다. 현장에서는 가상 출고 순서를 매번 생성하지 않는 AI를 1차 추천에 활용하고, 추천이 불리했던 사례를 미래 탐색으로 검토한다.

5.4. 결과 검증과 해석 범위

224개 배치와 다섯 방법의 작업 기록 1,120개를 다시 실행해 최상단 이동, 최대 적재 높이, 요청 순서의 준수 여부를 점검한 결과, 누락이나 중복 없이 전체 출고가 완료되었고 재집계한 재취급 횟수도 보고 결과와 일치하였다. 작은 규모의 8개 배치에서는 미래 출고 순서를 모두 아는 조건의 최적해를 계산하여 어떤 방법도 이 이론적 하한보다 적은 재취급을 기록하지 않았음을 확인하였고, 미래 요청 순서만 바꾸는 검사에서도 최초 이동 선택은 같게 유지되었다.

이번 결과는 공개 연구 자료의 배치와 출고 확률로 같은 규격의 컨테이너가 놓인 한 구역을 비교한 실험에서 얻었으며, 신규 반입, 장비 이동거리, 크레인 간 간섭과 작업시간 및 운영비에 미치는 효과는 6장의 시범 운영에서 확인한다.

6. 현장 적용과 실행 계획

6.1. 운영 데이터와 시스템 연계 방안

현장 연계는 공개 자료 실험에 이은 후속 단계로, 실제 터미널 자료를 사용해 야드의 한 구역에서 시작한다. 컨테이너 식별번호, 현재 위치와 적재 높이, 반입 및 출고 이력, 현재 출고 요청을 연계하고, 규격, 중량, 냉동 및 위험물 여부는 이동 가능 위치의 조건으로 사용한다. 작업 확정 직전에는 위치 정보를 다시 확인해 추천을 갱신하고, 추천 위치와 실제 이동 위치, 재취급 횟수, 작업시간, 채택 여부와 변경 사유를 기록한다.

6.2. 단계별 시범 운영 계획

데이터 제공과 운영 협의가 끝난 시점부터 8주간의 시범 운영을 표 6-1과 같이 진행하며, 과거 기록 검증은 학습 기간과 평가 기간을 시간 순서로 나누어 수행한다.

표 6-1. 단계별 시범 운영 계획

단계	기간	주요 작업	확인할 내용
자료 정리와 조건 확인	1~2주	위치 및 출고 이력 연결, 적재 제한과 예외 조건 정리	자료 누락과 위치 불일치, 후보 생성의 적절성
과거 기록 기반 검증	3~4주	과거 배치 재현, 현장 출고 확률 추정, 규칙과 AI 및 탐색 방법 비교	별도 평가 기간의 재취급과 계산시간, 제약 위반 여부
현장 추천 병행 기록	5~6주	기존 작업을 유지하면서 AI 추천을 함께 기록	추천 위치의 사용 가능 여부와 담당자 검토 의견
제한된 구역의 시범 적용	7~8주	담당자 확인 후 추천 적용, 실제 작업 결과 수집	재취급, 작업시간, 추천 채택률과 변경 사유

6.3. 필요 인력과 비용 산정 항목

시범 운영의 개발 업무는 터미널 시스템의 위치와 출고 이력 연계, 현장 자료를 이용한 출고 확률 추정과 모형 재학습, 추천 화면과 작업 기록 기능의 현장 환경 적용이다. 인력은 적재 기준과 추천의 현장 적합성을 검토하는 운영 담당자, 확률 추정과 모형 학습 및 평가를 맡는 데이터 담당자, 시스템 연계와 작업 기록 수집을 맡는 연계 담당자로 구성한다. 사업비는 인건비 단가, 참여 기간과 참여율, 연계 개발 범위를 터미널과 협의해 확정한 뒤 산정하며, 운영 확대 여부는 시범 구역의 재취급과 장비 가동시간 변화를 구축 및 유지 비용과 비교해 결정한다.

7. 기대효과와 관리 방안

7.1. 기대효과와 성과 측정 지표

이번 평가에서 AI는 출고 우선순위 규칙보다 재취급을 199회(9.4%) 줄였다. 이 감소 수준을 출고 컨테이너 100만 개 기준으로 환산하면 약 4.8만 회의 추가 이동을 줄이는 규모에 해당한다. 재취급 1회당 작업시간을 2.5분으로 적용할 경우, 약 2,000시간의 장비 작업량에 해당한다.[5] 전기식 RTG 크레인의 시간당 유지보수비 19.4유로와 2024년 연평균 환율을 적용한 유지보수비 환산액은 약 5,700만 원이다.[6][7] 환산 과정은 표 7-1과 같으며, 현장 도입 후의 실제 효과는 표 7-2의 지표로 확인한다.

표 7-1. 출고 컨테이너 100만 개당 재취급 감소의 환산

항목	적용값	산정 근거
재취급 감소량(출고 100만 개당)	약 4.8만 회	199 ÷ 4,132 × 1,000,000
장비 작업시간	약 2,000시간	48,160.697회 × 2.5분 ÷ 60
유지보수비 단가	28,615원/시간	19.4유로/시간 × 1,475원/유로
유지보수비 환산액	약 5,700만 원	2,006.696시간 × 28,615원

주: 동일한 개선 수준이 유지되고 유지보수비가 작업시간에 비례한다고 가정한 환산 결과이다. 전력비, 인건비와 감가상각비는 제외

표 7-2. 현장 적용 성과 지표

지표	측정 방법
컨테이너당 재취급 횟수	총 재취급 횟수를 출고 컨테이너 수로 나누어 산출
출고 요청 처리시간	요청 접수부터 출고 완료까지 소요시간의 평균과 95백분위 산출
추천 응답시간	입력부터 추천 결과 반환까지 소요시간 측정
추천 채택률	유효 추천 건수 대비 담당자 채택 건수의 비율 산출
제약 위반 및 예외 건수	적재 조건 위반, 위치 불일치, 수동 전환 건수 집계

주: 95백분위 처리시간은 전체 요청의 95%가 그 시간 이내에 완료되는 수준

7.2. 운영 위험과 대응 방안

표 7-3의 항목을 점검하고, 담당자의 최종 확인과 수동 전환 절차를 유지한다.

표 7-3. 현장 적용의 주요 위험과 대응 계획

관리 항목	대응 계획
데이터 확보	터미널 위치와 출고 이력의 제공 범위 및 갱신 주기 협의, 누락과 위치 불일치 점검, 현장 이력 기반 출고 확률 재추정
기술 구현	출고 패턴 변화와 예측 오차 점검, 추천 후 재취급이 증가한 사례의 미래 탐색 재검토, 확률 추정과 비용 예측 모형 갱신
현장 적용	규격, 중량, 보관 조건과 장비 접근 여건 반영, 위치 정보가 맞지 않거나 후보 확인이 어려우면 기존 작업 절차로 전환
보안 및 개인정보	분석에 필요한 운영 자료만 수집, 개인 식별정보 제외 또는 가명 처리, 접근 권한과 이용 기록, 보관 기간 관리
저작권	Mendeley 연구 자료[3]의 CC BY 4.0 조건에 따라 저자, 출처, 버전, 이용허락과 변경 사항 명시, 화면과 배포 자료에 출처 표시

관리 항목	대응 계획
규제	도입 전 관련 안전 기준과 터미널 작업 절차 확인, 담당자 승인 범위와 책임 설정, 장비 제어 연계는 별도 안전 검토 후 추진

7.3. 결론과 후속 검증 과제

Yardwise는 현재 적재 상태와 출고 확률로 이동 위치별 후속 재취급의 상대 비용을 예측한다. 평가용 224개 배치에서 재취급은 출고 우선순위 규칙보다 199회(9.4%), 확률 위험 규칙보다 176회(8.4%) 적었고, 전체 이동은 3.2% 줄었다. 향후 터미널 이력을 연결한 시범 운영으로 재취급 감소가 실제 작업시간과 운영비 절감으로 이어지는지 평가한다.

참고문헌

[1] Zhang, Z., Tan, K. C., Qin, W., Chew, E. P., & Li, Y. (2025). A data-driven approach to solving the container relocation problem with uncertainties. *Advanced Engineering Informatics, 65*, Article 103112. https://doi.org/10.1016/j.aei.2025.103112

[2] 부산항만공사. (2026. 2. 12.). 「부산항만공사, '부산항 AX(AI 대전환) 추진계획' 본격 실행」 [보도자료].

[3] Zhang, Z. (2024). *Probabilistic Container Relocation Problem* (Version 3) [데이터 세트]. Mendeley Data. https://doi.org/10.17632/3j52cjrm52.3

[4] Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning, 63*, 3–42. https://doi.org/10.1007/s10994-006-6226-1

[5] Stoilova, S. D., & Martinov, S. V. (2019). Choosing the container handling equipment in a rail-road intermodal terminal through multi-criteria methods. *IOP Conference Series: Materials Science and Engineering, 664*(1), 012032. https://doi.org/10.1088/1757-899X/664/1/012032

[6] European Commission, Directorate-General for Energy, DNV, Trinomics, & LBST. (2024). *Port electricity commercial model (project pilot): Final report*. Publications Office of the European Union. https://doi.org/10.2833/7036399

[7] 국회예산정책처. (2025). 『2025 대한민국 경제』. 국회예산정책처.